Análisis estadístico y opinión Pública

Clase 3: Introducción a la estadística descriptiva

Frecuencias, porcentajes, medidas de tendencia central

Francisco Villarroel Riquelme (CICS- UDD)

Universidad del Desarrollo
Facultad de Comunicaciones

¿Qué veremos hoy?

- Conoceremos la diferencia entre estadística descriptiva e inferencial
- Observaremos los computos bàsicos de la estadística descriptiva: frecuencias, porcentajes y medidas de tendencia central

Repaso: Muestras

- Población (cantidad total de personas sujeto de ivnestigación) y muestra (subgrupo que se accede para estudiar un fenómeno)
- Para saber cuánta muestra necesito, debo considerar nivel de confianza y error de muestra
- **El nivel de confianza** es el cálculo probabilístico sobre si la muestra es representativa o no
- **El error de muestreo** es el error de estimaciòn admisible desde la muestra hacia la población

El muestreo más conocido es el *muestreo aleatorio simple*, donde todos tienen la misma probabilidad de ser elegidos.

Otros muestreos probabilísticos importantes: por conglomerado (niveles geográficos diferentes) y muestreo estratificado (variables sociales diferentes)

Estadística descriptiva

Estadística descriptiva != Inferencial

Descriptiva	Inferencial
Permite resumir y describir características básicas de los datos	Permite deducir características de la población
Permite una comprensiónn inicial de características y patrones	Permite predecir, inferir diferencias, generalizar, evaluar hipótesis
Medidas básicas: Tendencia central, dispersión y posición	Medidad básicas: Intervalos de confianza, diferencia entre grupos, regresiones

La visualización de datos también es un mecanismo descriptivo

Niveles de análisis

1. **Estadística univariada:** Revisar la forma, características y patrones de una sola variable.

2. **Estadística Bivariada:** Analizar el comportamiento de una variable dependiente Y con una independiente X

3. **Estadística multivariada:** Analizar el comoprtamiento de una variable dependiente Y con más de una variable independeiente $X_1, X_2, \ldots, X_n$

Estadística descriptiva

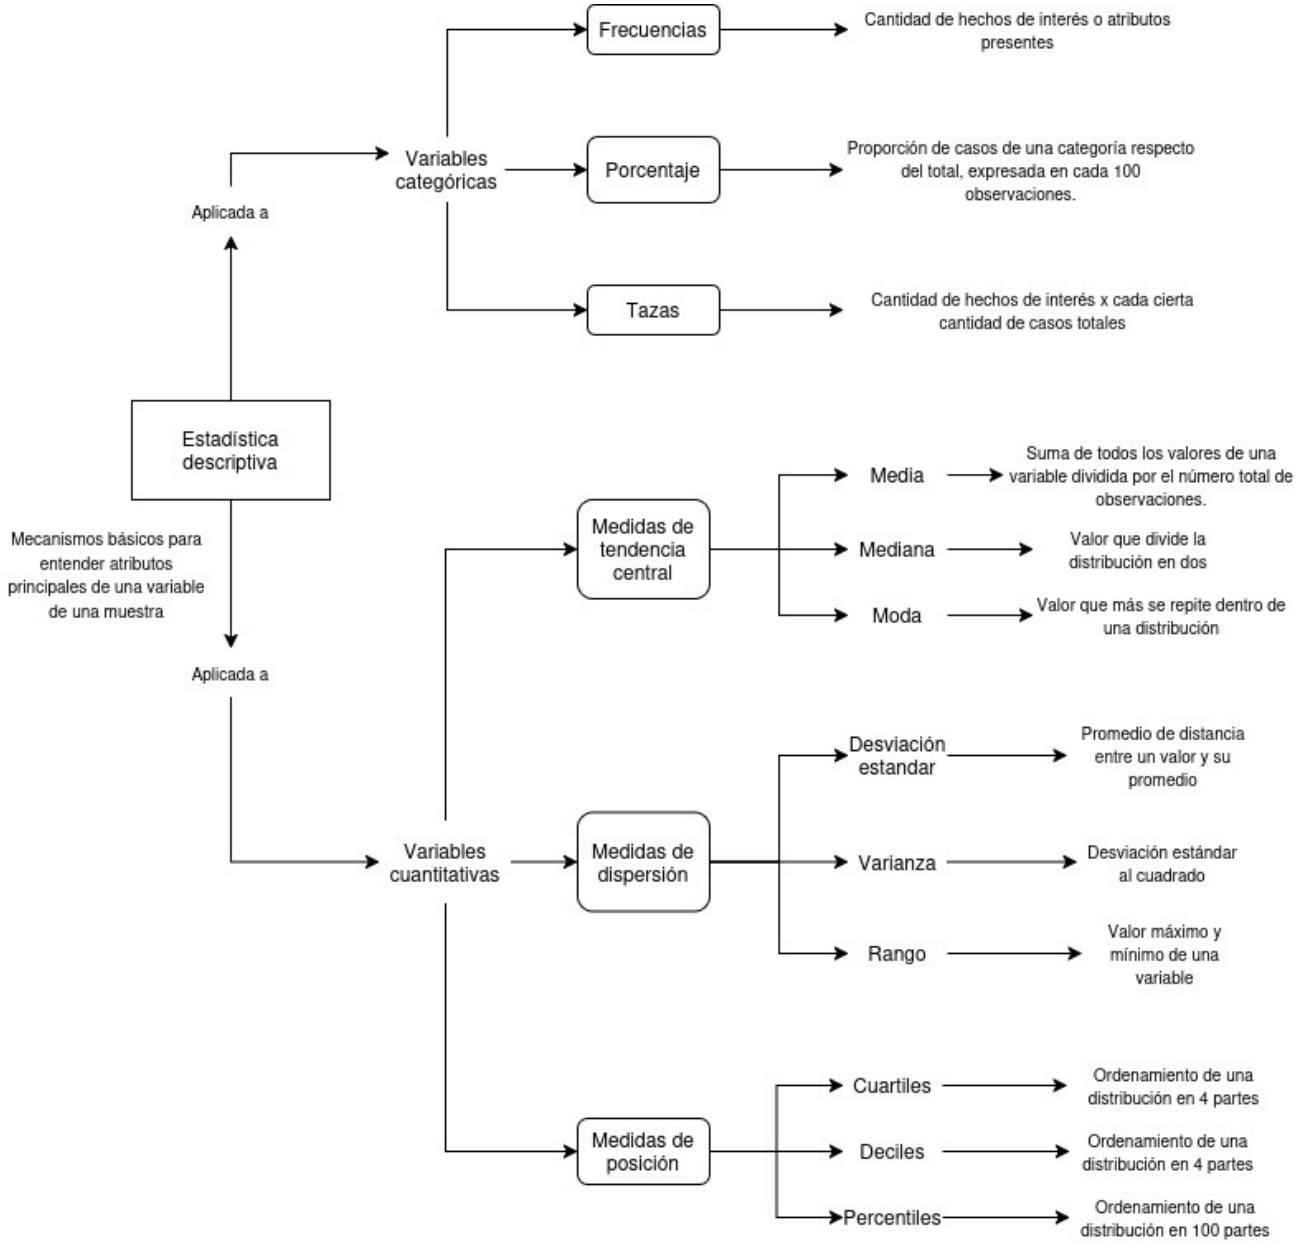
Estadística descriptiva
Mecanismos básicos para entender atributos principales de una variable de una muestra
Aplicada a
Variables categóricas
Frecuencias
Cantidad de hechos de interés o atributos presentes
Porcentaje
Proporción de casos de una categoría respecto del total, expresada en cada 100 observaciones.
Tazas
Cantidad de hechos de interés x cada cierta cantidad de casos totales
Aplicada a
Variables cuantitativas
Medidas de tendencia central
Media
Suma de todos los valores de una variable dividida por el número total de observaciones.
Mediana
Valor que divide la distribución en dos
Moda
Valor que más se repite dentro de una distribución
Medidas de dispersión
Desviación estandar
Promedio de distancia entre un valor y su promedio
Varianza
Desviación estándar al cuadrado
Rango
Valor máximo y mínimo de una variable
Medidas de posición
Cuartiles
Ordenamiento de una distribución en 4 partes
Deciles
Ordenamiento de una distribución en 4 partes
Percentiles
Ordenamiento de una distribución en 100 partes

Frecuencias y porcentajes

Frecuencia

- Conteo ordenado por cada etiqueta existente
- Para variables cualitativas, lo primero que hacemos es observar cuántas hay de cada categoría
- Puede sonar básico, pero es lo primero que se hace y a veces se encuentran sorpresas (resultados no esperados)
- Ayuda a evaluar si hay errores de datos (Variables que en alguna categoría no tienen a nadie son .. sospechosas)

Porcentajes:

- A veces el conteo no dice mucho
- El porcentaje entrega más información porque es referencial del grupo (ej: categoría "mujeres" respecto de "Hombres")
- Fórmula de cálculo: cantidad de conteos de una categoría dividida por la cantidad de observaciones totales * 100

Tasa

- Medición de frecuencia para observar un evento de interés en torno a la población general
- Utilizado en epidemiología.
- Habitualmente se usan múltiplos de mil para comparar

ej: 200 de cada 1000 niños tienen una enfermedad respiratoria antes del año ej: 4 de cada 10 personas aprueba al presidente José Antonio Kast ej: La tasa de mortalidad en Chile en 2022 fue de 7,2 muertes por cada mil habitantes (7,2‰)

Ejercicio asistido:

De la muestra obtenida, 36 personas creen que estamos siendo vigilados por agencias gubernamentales.

Cuál es el porcentaje y la tasa? son 95 casosa válidos.

De la encuesta realizada, 19 personas creen que es bueno/muy bueno tener un líder fuerte que no le importe ni el congreso ni elecciones.

Calcule su porcentaje y tasa cada 10 personas. El total de datos válidos es 95

Estadística descriptiva para variables cuantitativas

Media

- Estadístico de tendencia central más útil para variables cuantitativas
- Es sencillo de computar y comprender
- Desventaja: es muy sencible en variables con valores extremos (no tienen distribución normal)
- Valores extremos pueden hacer "bajar" o "subir" la media
- Es importante computar sólo casos válidos

Se calcula mediante:

$$\overline{X} = \frac{\sum X}{n}$$

donde:

$\overline{X}$ = Media o promedio de variable X
$\sum X$ = Suma de todos los valores de X
n = número de observaciones

Mediana

- Es, por definición, el valor que corta la mitad una muestra
- Es una medida mucho menos sensible a valores extremos a diferencia de la media
- Pero es sensible a cambios de cantidad de observaciones
- Es una buena medida cuando la distribución no es normal o hay otros sesgos

Forma de calcular:

1. Se ordena de menor a mayor todos los valores de la variable
2. El número de valores existentes se divide en dos
3. La mediana es el que divide la muestra a la mitad (si es impar)
4. Si la muestra es par, es la media de los dos valores límites

Moda

- Puntuación con mayor frecuencia dentro de una serie de observaciones de una variable
- Es la "más popular"
- Es un estadístico de poca utilidad
- No sugiere mucho de los demás puntos

Forma de calcular:

1. Agrupa las puntuaciònes en una distribuciòn de frecuencias (contar cuántos hayd e cada valor)
2. identificar el que màs se repite

Ejercicio grupal:

[163,169,173,163,160]

Medidas de dispersión y posición

¿Qué son las medidas de dispersión?

- Así como las medida de tendencia central nos ayudan a comprender donde está la mayoría de los datos agrupados
- Las medidas de dispersión nos ayudan a entender *qué tan separados están los datos unos de otros*
- Las medidas de dispersión nos ayudan a entender la extensión de la distribución y mejora la comprensión de la concentración de valores

Rango

- Son los valores máximos y mínimos que toma un conjunto de observaciones de una variable
- Es para variables cuantitativas, y por tanto pueden tener un rango de $-\infty$ a ∞
- Su forma por sí sola da poca información. Sólo son los límites de la distyribución, *no su forma*.

Desviación estandar

- Describe *cuán lejos están las puntuaciones de una variable respecto de la media*
- Se utiliza en variables de razón o cuantitativas contínuas
- Permite entender, junto a la media, donde se ubica la mayoría de la distribución
- ej: cuando señalan que un estudio tiene $\mu = 22.4$ y SD=4.3, quiere decir que la mayoría de la población está entre los 18 y los 26 años
- Problema: como es a partir de la media, también se infla por valores extrenmo

forma de cálculo:

$$S_X = \sqrt{\frac{\sum(X - \overline{X})^2}{n-1}}$$

donde:

S_X = Desviaciòn estandar de la variable X

$\overline{X}$ = Media de X

n = Número de observaciones o tamaño muestral

Medidas de posición

Cuartiles, Quintiles y deciles

- Formas de subdivisión del conjunto de datos
- Habitualmente divididos en cuartiles (4 partes), quintiles (5 partes) y deciles (10 partes)
- Permite entender cómo es la forma de la distribución en toda la extensión

forma de cálculo:

1. Se divide el conjunto de observaciones en los grupos desesados
2. Se aplica habitualmente el promedio por cada grupo para observar tendencia central agrupada
3. Otras formas son con frecuencias acumuladas y porcentajes acumulados

Calcule la media, mediana, moda y desviación estander de:

1: [167,174,175,170,185,173,170,171,158,164]

2: [164,169,167,172,160,163,157,163,180,180]

¿Qué es una distribución?

Cuando medimos algo en muchas personas, los valores no son todos iguales.
La **distribución** es simplemente *el patrón* de cómo se reparten esos valores.

De datos sueltos a una forma

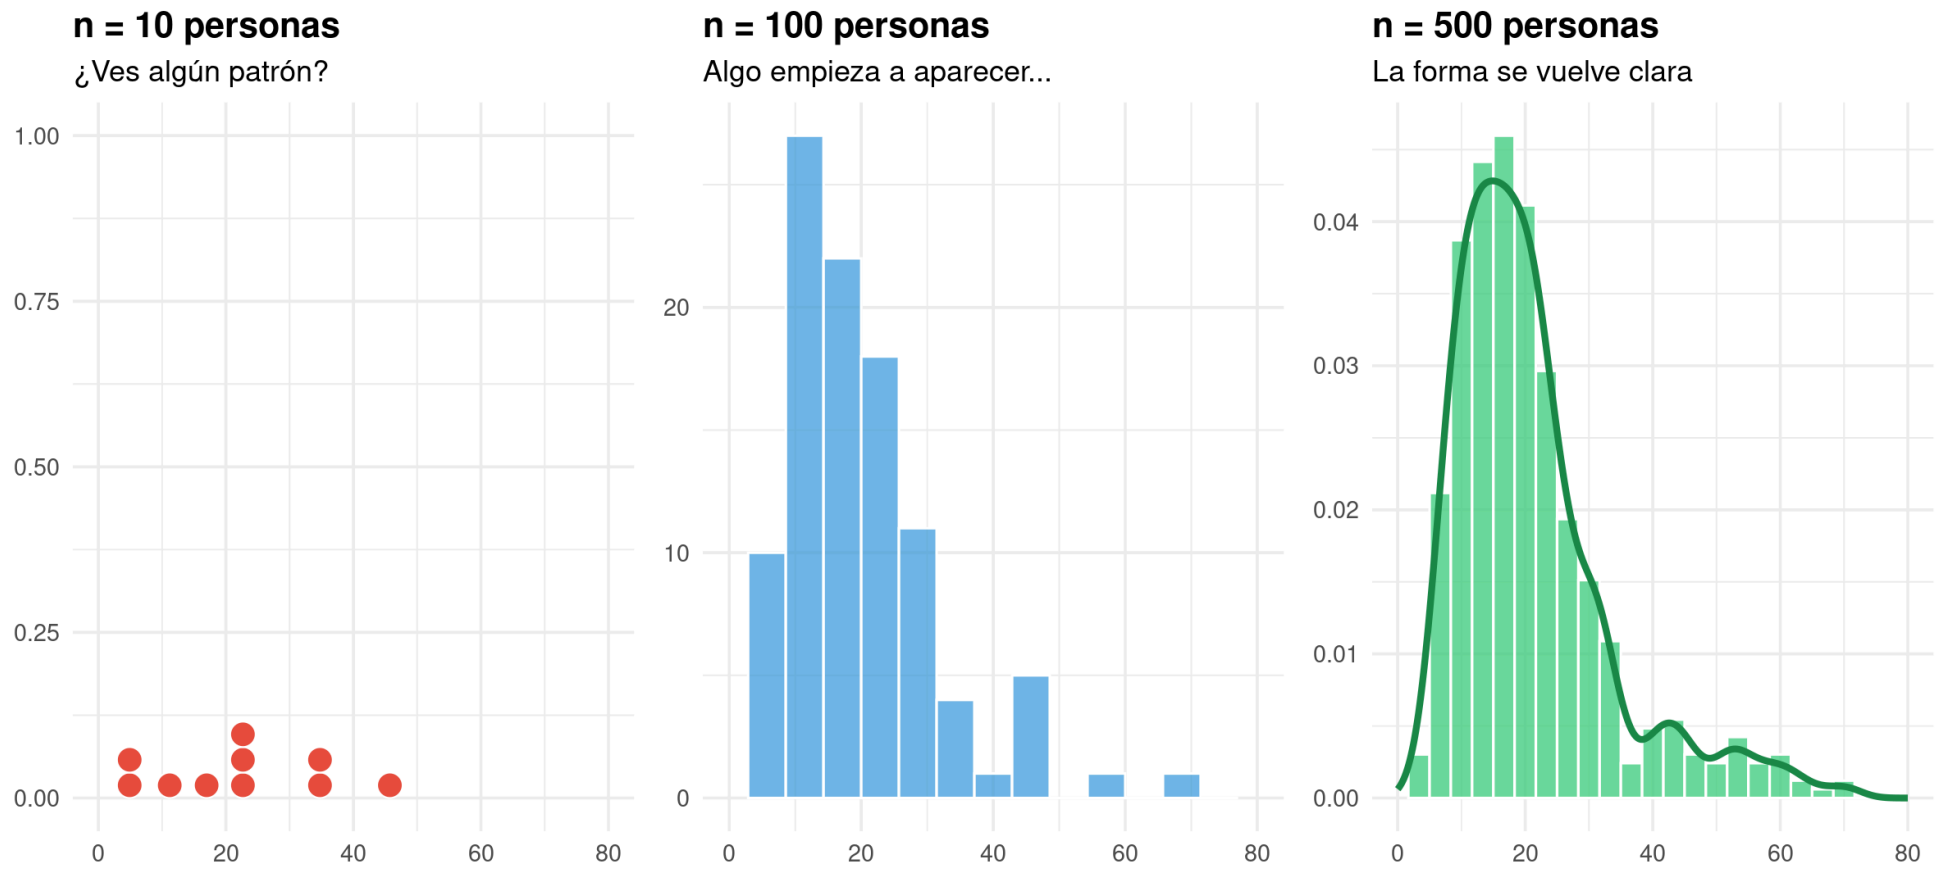

Minutos diarios viendo noticias — cada barra agrupa a personas con valores similares.
Con más datos, emerge la **distribución**: la "firma estadística" de ese fenómeno.

Del plano cartesiano a la distribución

Cada panel agrega un elemento nuevo

1. El plano cartesiano

Dos ejes que se cruzan en el origen (0, 0)

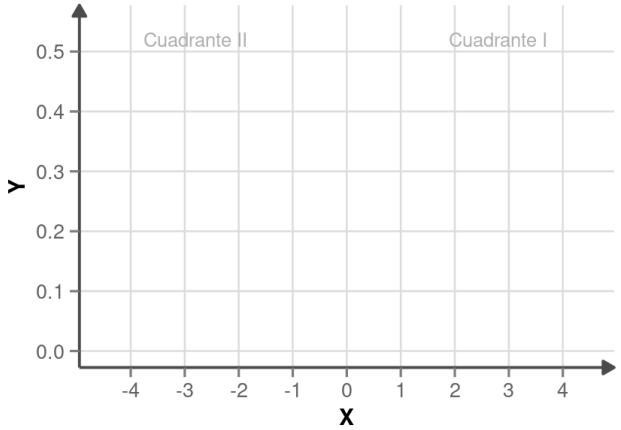

2. El eje X (horizontal)

Representa el valor medido

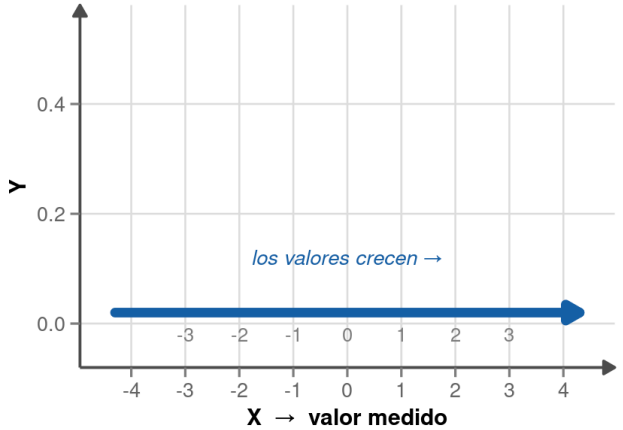

3. El eje Y (vertical)

Representa cuántas veces ocurre ese valor

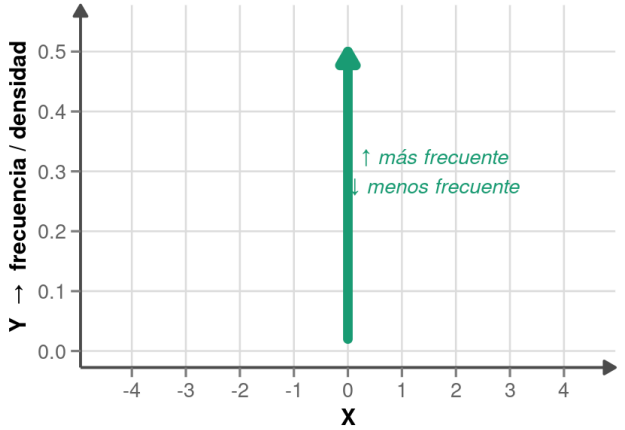

2. El eje X (horizontal)

Representa el valor medido

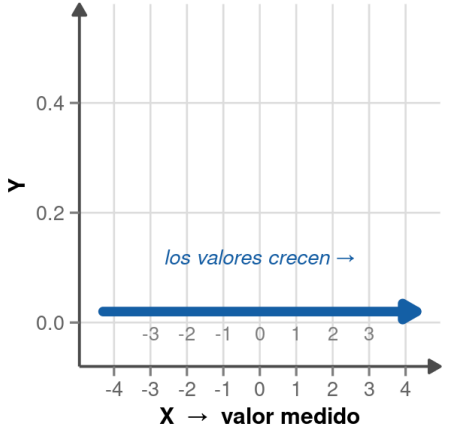

4. Un punto (x, y)

Posición horizontal = valor; altura = qué tan frecuente

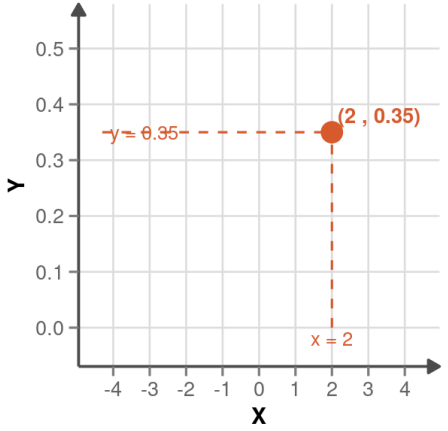

5. Muchos puntos → distribución

Cada barra = cuántas personas tienen ese valor en X

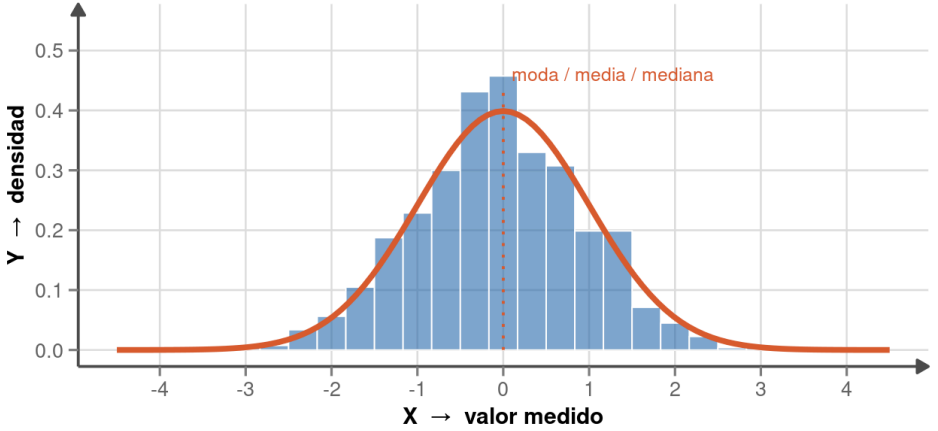

¿Qué es la Distribución Normal?

La distribución normal es una de las distribuciones de probabilidad más importantes en estadística. Se caracteriza por su forma de campana y su simetría alrededor de la media.

Distribución Normal

Propiedades de la Distribución Normal

- **Media, Mediana y Moda:** Todas son iguales y se encuentran en el centro de la distribución.
- **Unimodal:** Sólo hay un valor más repetido
- **Simetría:** Es perfectamente simétrica respecto a la media.
- **Curtosis:** Tiene una forma de campana, lo que significa que los datos se agrupan más cerca de la media.
- **Asintótica:** Las colas de la distribución se acercan al eje X pero nunca tocan.

Importancia de la Distribución Normal

- **Teorema del Límite Central:** Establece que la suma de un gran número de variables aleatorias independientes tiende a una distribución normal, sin importar la distribución original de las variables.
- **Modelos Estadísticos:** Muchos tests estadísticos y modelos están basados en la suposición de que los datos siguen una distribución normal.
- **Inferencia Estadística:** Permite hacer inferencias sobre la población basadas en muestras.

Visualización de Distribuciones Normales

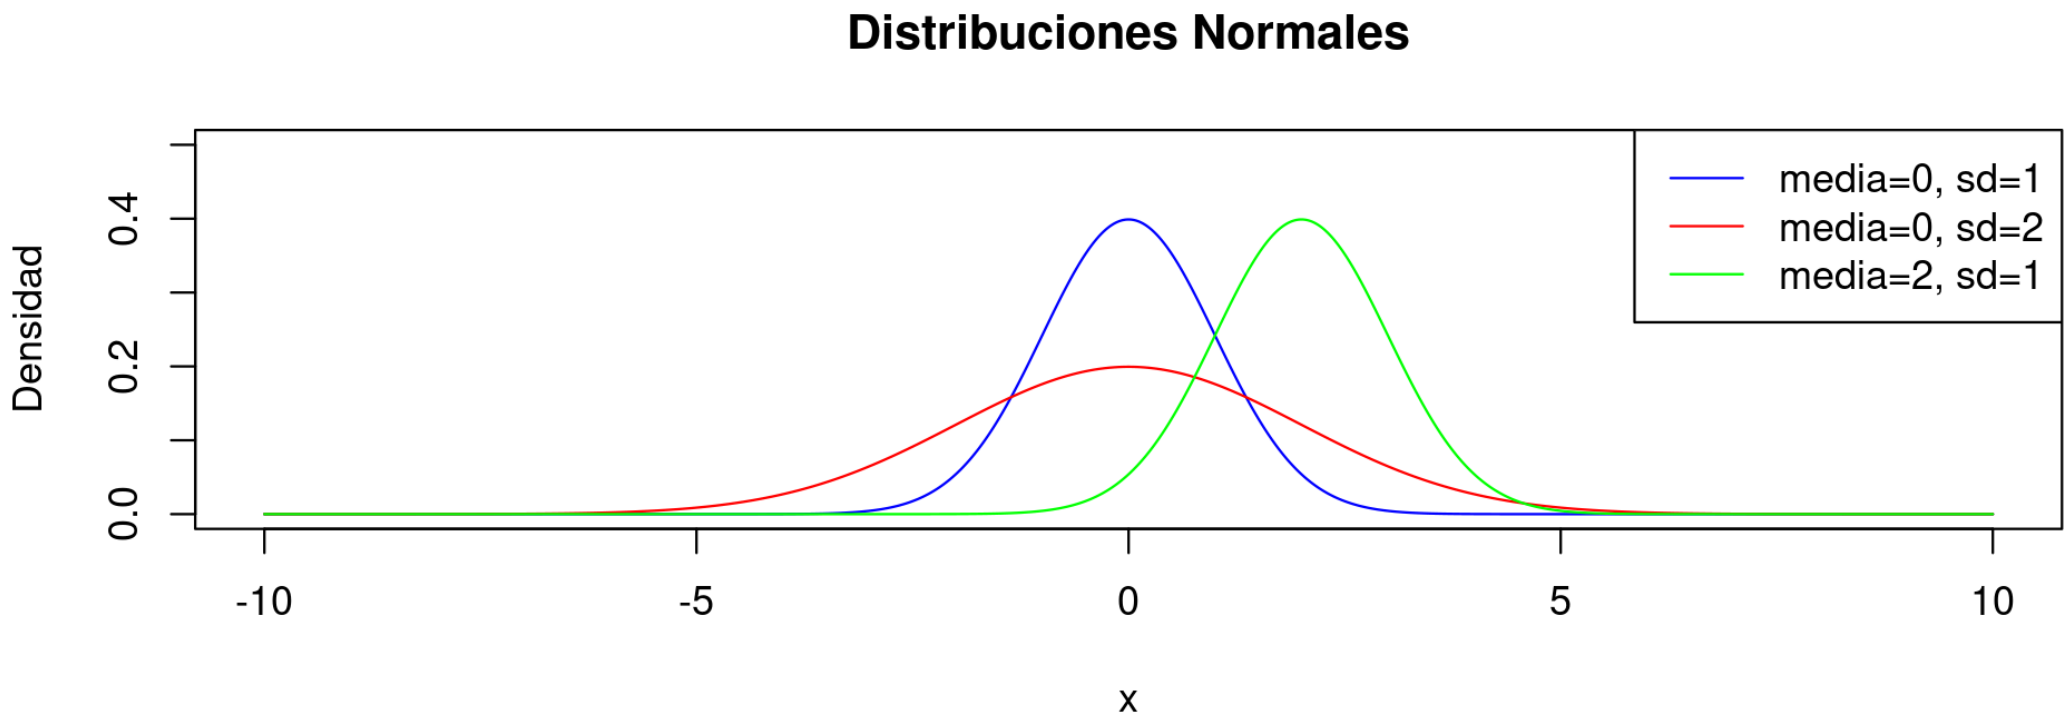

Distribuciones Normales con diferentes medias y desviaciones estándar

Visualización de Diferentes Distribuciones

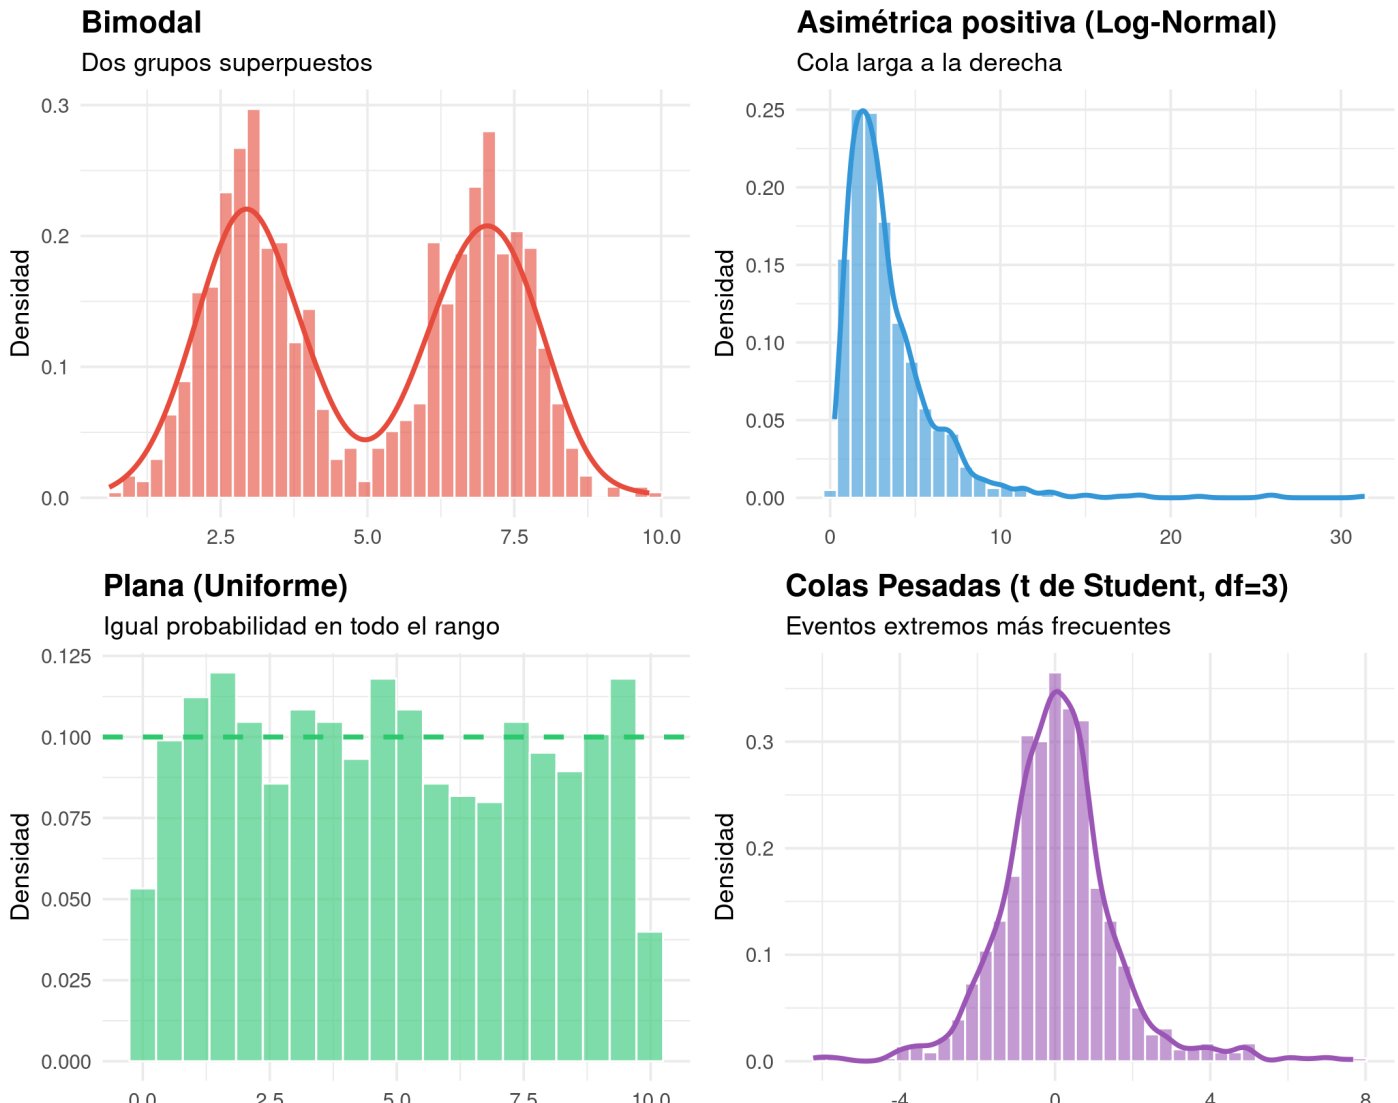

Ejemplos de distribuciones normales

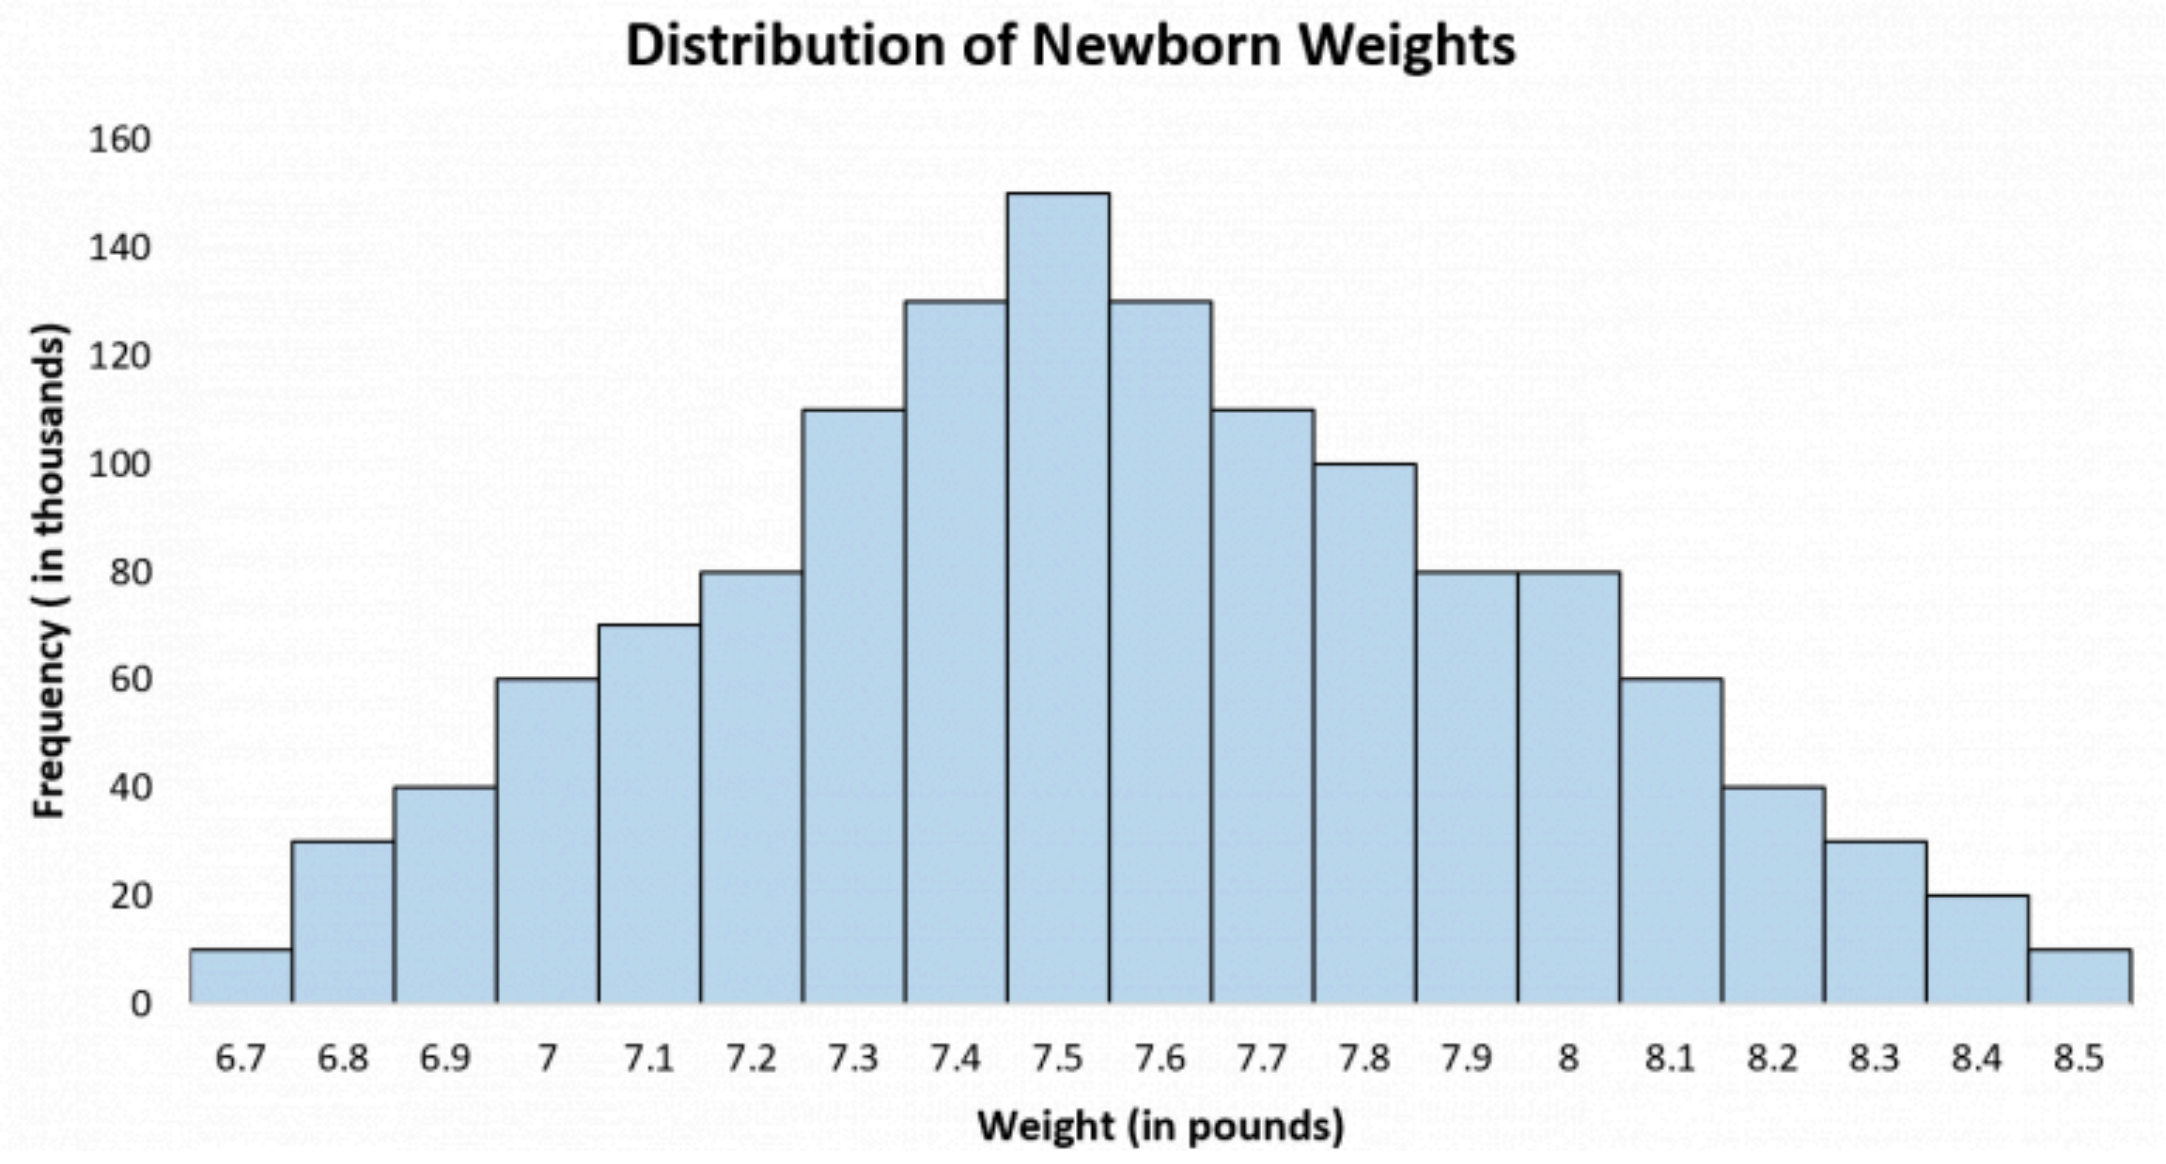
Distribution of Newborn Weights
Frequency (in thousands)
160
140
120
100
80
60
40
20
0
6.7
6.8
6.9
7
7.1
7.2
7.3
7.4
7.5
7.6
7.7
7.8
7.9
8
8.1
8.2
8.3
8.4
8.5
Weight (in pounds)

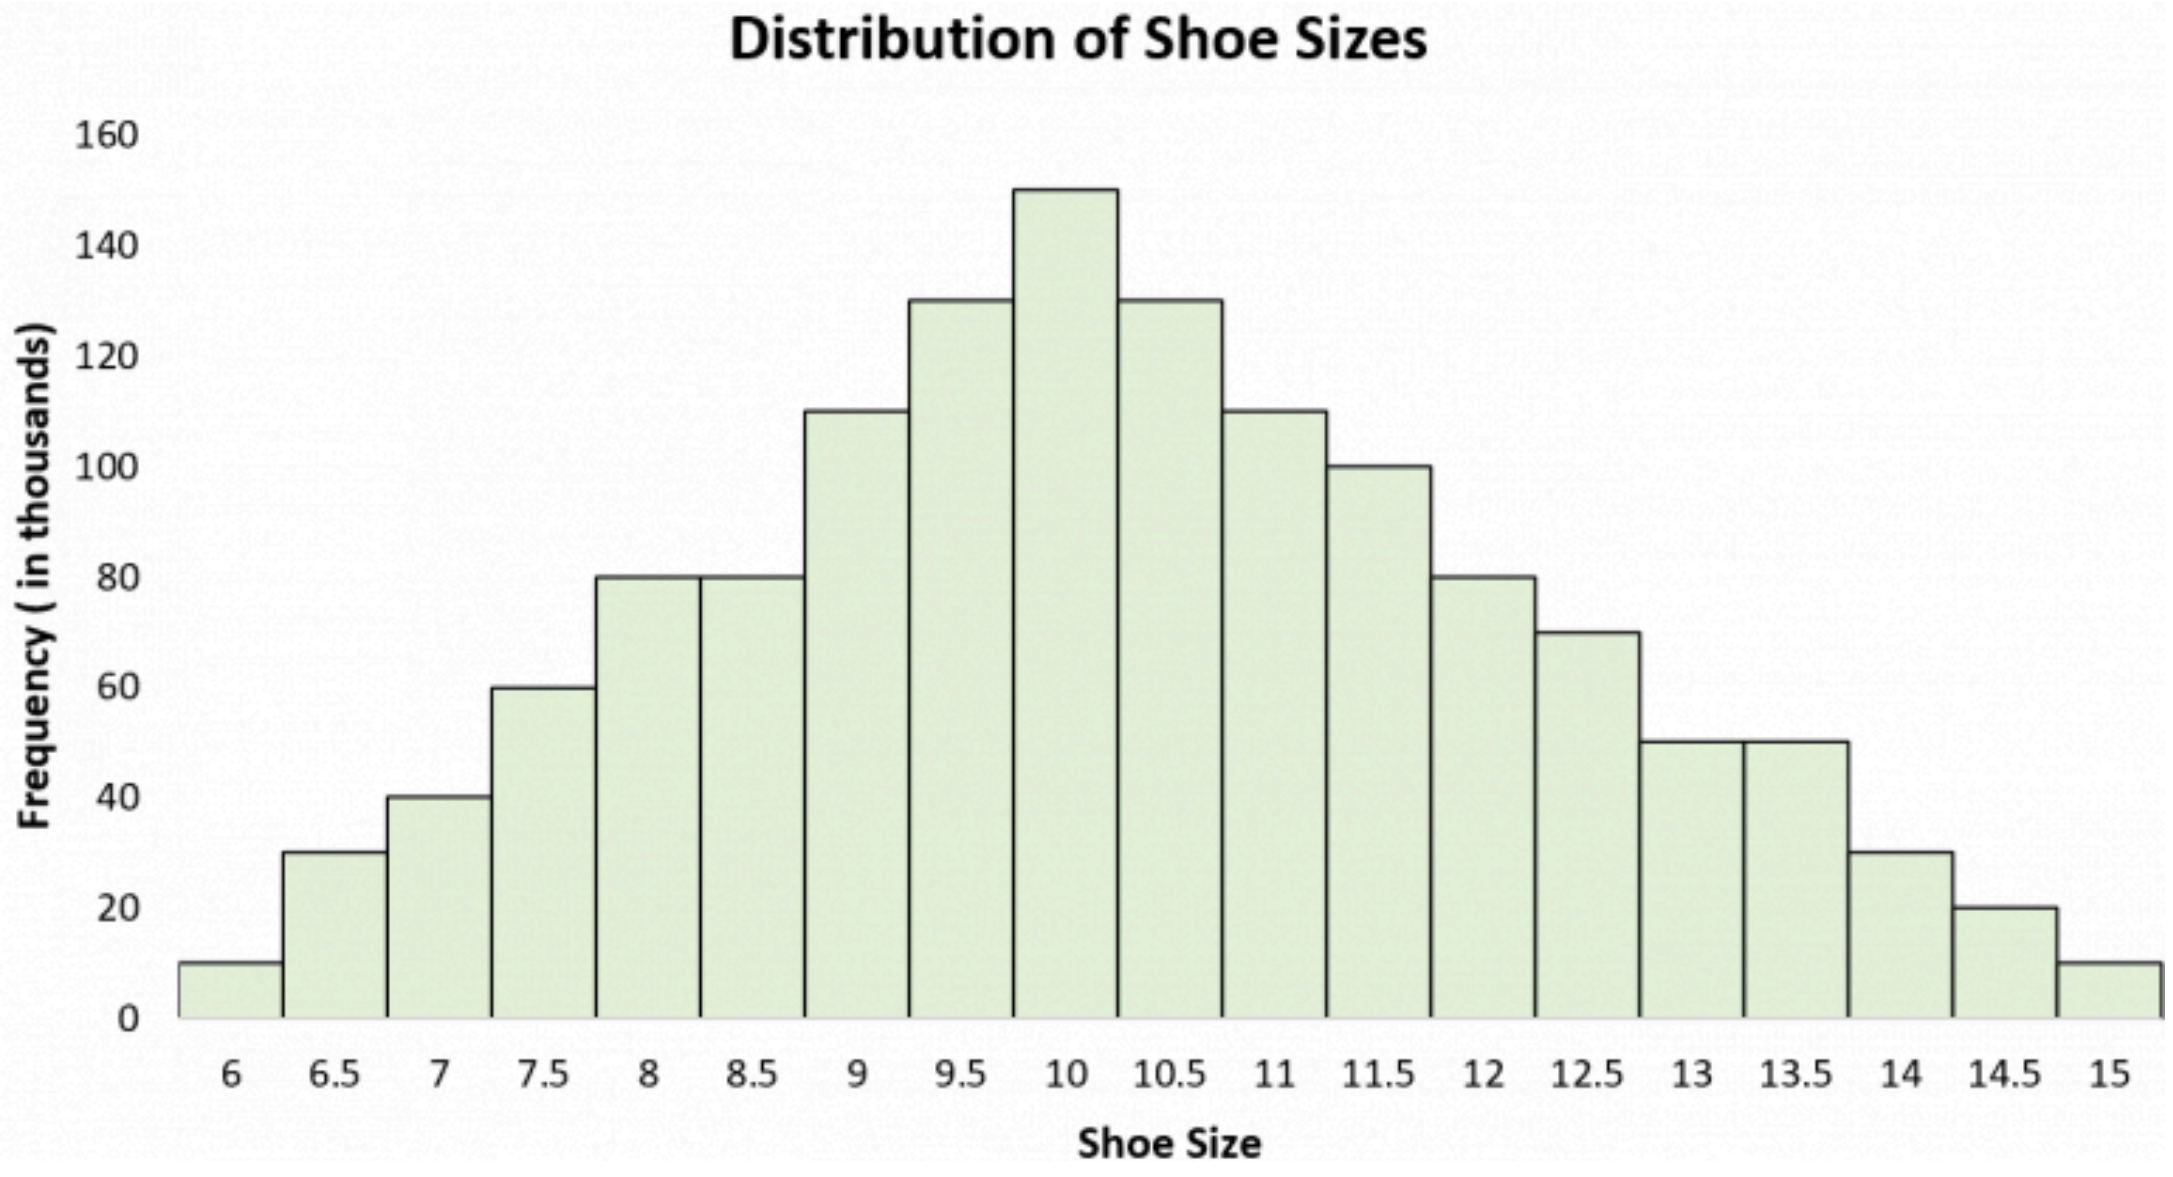
Distribution of Shoe Sizes
Frequency (in thousands)
160
140
120
100
80
60
40
20
0
6
6.5
7
7.5
8
8.5
9
9.5
10
10.5
11
11.5
12
12.5
13
13.5
14
14.5
15
Shoe Size

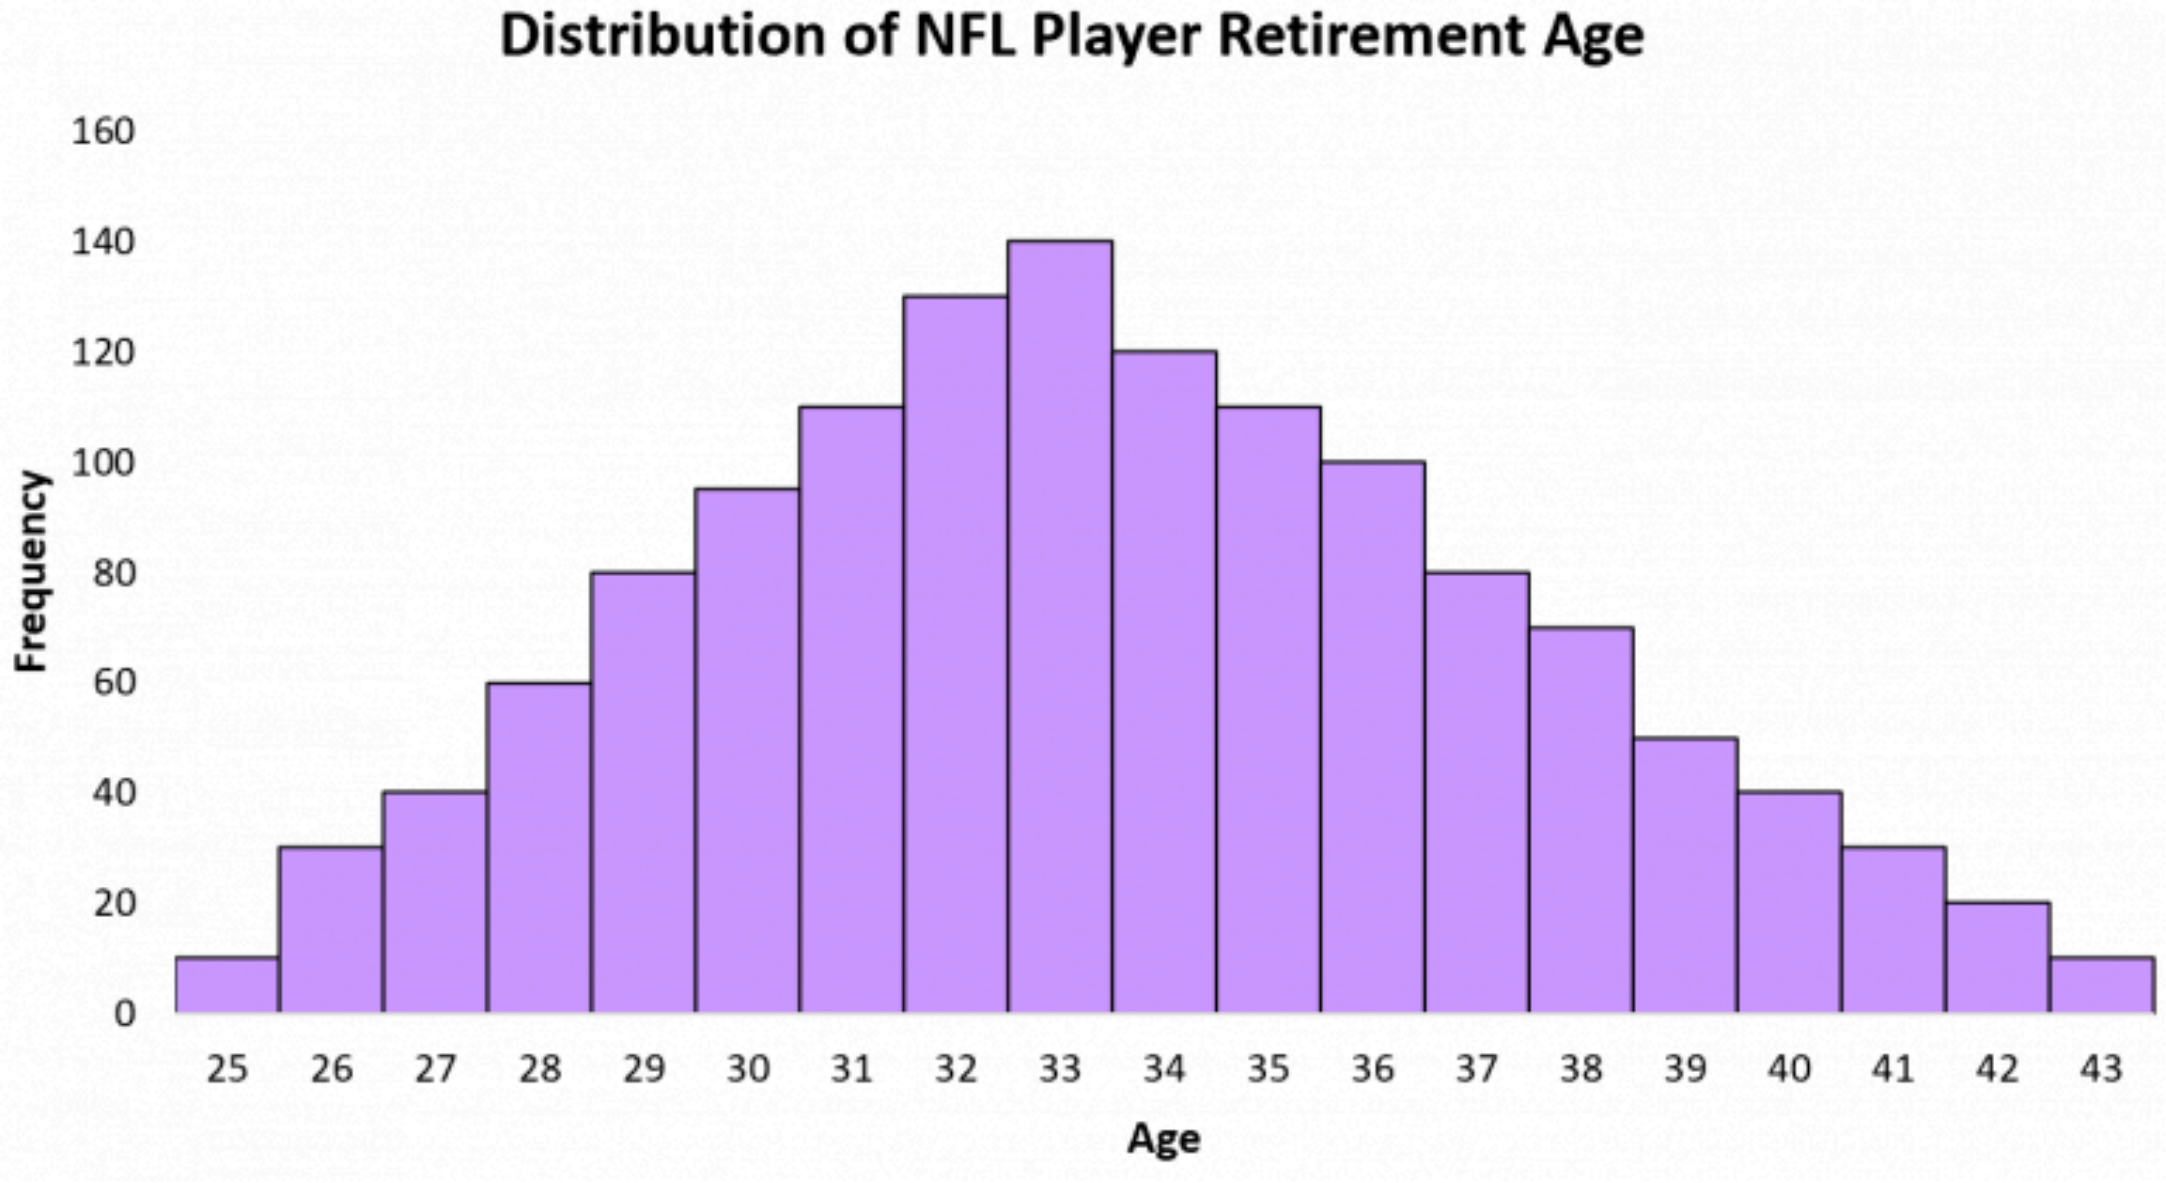
Distribution of NFL Player Retirement Age
Frequency
160
140
120
100
80
60
40
20
0
25
26
27
28
29
30
31
32
33
34
35
36
37
38
39
40
41
42
43
Age

Bimodal: Polarización de opinión

Tema valórico en encuesta (tipo ANES/CADEM)

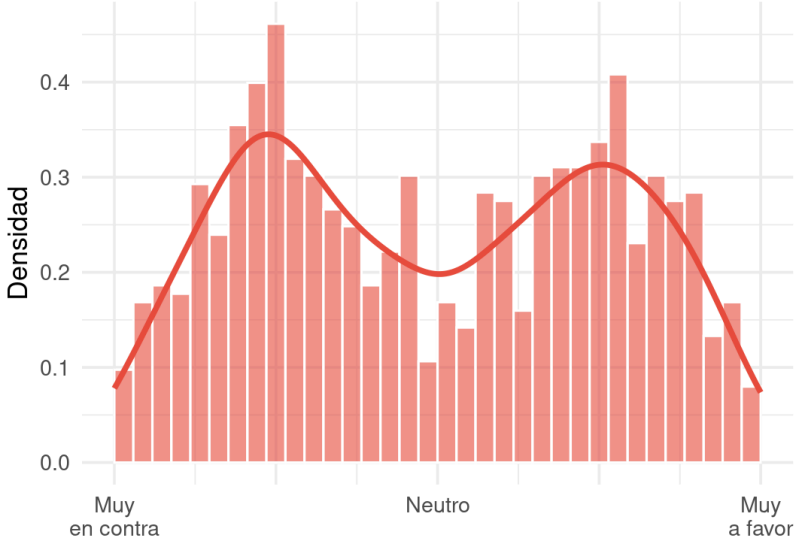

Power Law: Seguidores en RRSS

Distribución de seguidores (Twitter/Instagram)

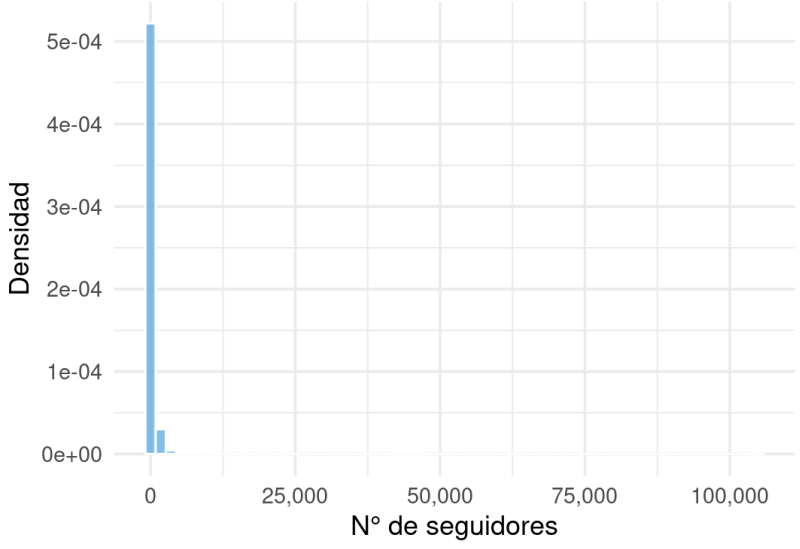

Log-Normal: Tiempo leyendo noticias

Minutos de exposición por visita (mediana ~1.5 min)

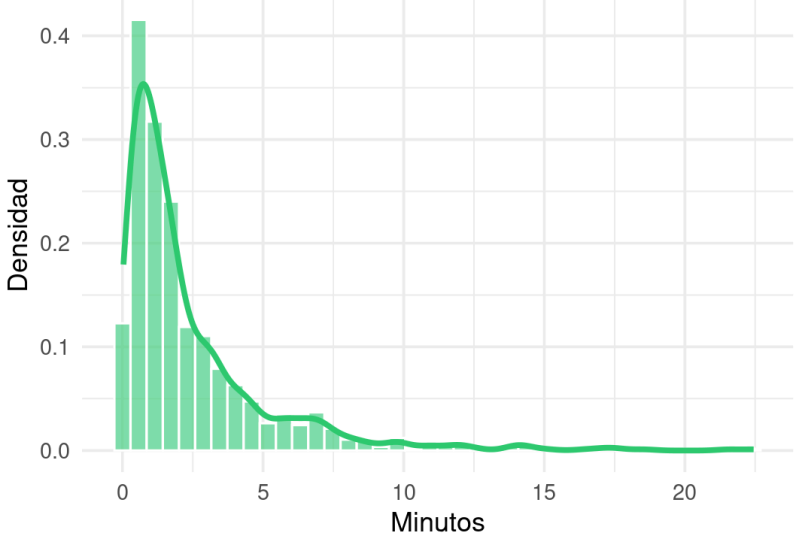

Plana: Likert en tema de baja implicación

Sin actitud formada → respuestas equiprobables

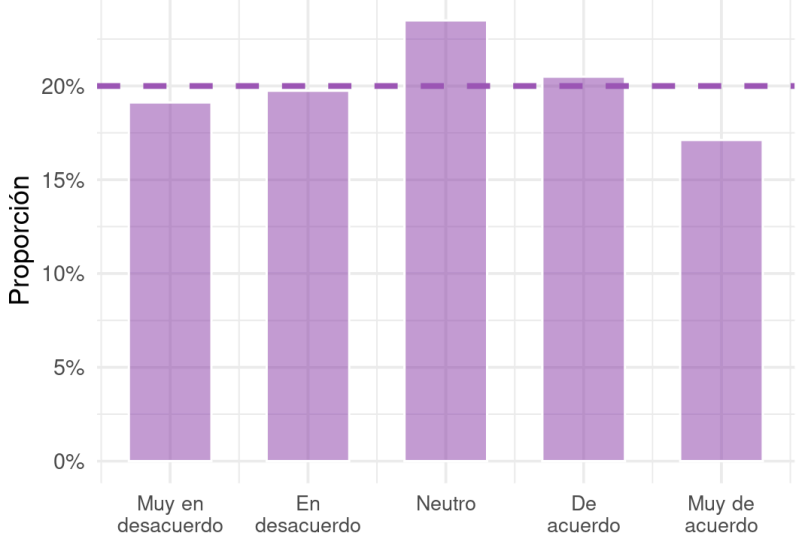

¡Gracias!

fvillarroelr@udd.cl

Slide creado con el paquete **xaringan**.

El chakra viene de remark.js, **knitr**, y R Markdown. Este slide fue creado por **xaringan** y **XaringanThemer**