Análisis Estadístico y Opinión Pública

Clase 7: Estadística Bivariada — Tablas Cruzadas

Francisco Villarroel Riquelme | CICS — UDD | 2026-04-20

¿Qué veremos hoy?

¿Qué son las tablas cruzadas?

Definición, estructura y tipos de variables que pueden analizarse.

Análisis clásicos

Ejemplos típicos de uso en opinión pública e investigación social.

Cómo interpretar

Lectura por filas, por columnas y totales marginales.

Objetivo central: Al terminar la clase podrás construir, leer e interpretar una tabla cruzada, y decidir si la relación entre dos variables es estadísticamente significativa usando el test de Chi-cuadrado (χ^2).

Parte 1: Tablas de Contingencia

¿Qué es una Tabla de Contingencia?

Una **tabla de contingencia** (o tabla cruzada) es una herramienta estadística que organiza la frecuencia conjunta de **dos o más variables categóricas** en una matriz de filas y columnas.

¿Para qué sirve?

- Describir la distribución conjunta de dos variables
- Detectar patrones de asociación
- Base para pruebas de independencia estadística

¿Qué tipo de variables?

- Dos variables **cualitativas** (nominal u ordinal)
- Una cualitativa + una cuantitativa **categorizada**
- Ejemplos: sexo × preferencia; edad × medio informativo

Anatomía de una Tabla Cruzada

Ejemplo: ¿Leyó el diario en los últimos 3 días? (por género)

	Femenino	Masculino	Total fila
Sí	30	20	**50**
No	20	30	**50**
Total col.	**50**	**50**	**100**

Celdas internas
Frecuencias conjuntas de ambas variables

Marginales de columna
Total de cada categoría de la variable en columnas

Marginales de fila
Total de cada categoría de la variable en filas

Parte 2: Análisis clásicos con Tablas Cruzadas

Usos Clásicos en Opinión Pública

Las tablas cruzadas son el caballo de batalla de la investigación con encuestas. Algunos análisis estándar:

🗳️ Voto × Características sociales

- ¿Difiere la intención de voto según nivel educativo?
- ¿Varía la aprobación presidencial según región?

📺 Consumo de medios × Edad/Género

- ¿Los jóvenes prefieren internet y los adultos la TV?
- ¿Las mujeres consumen más prensa escrita que los hombres?

Confianza institucional × Nivel educativo

- ¿A mayor educación, menor confianza en el Congreso?
- ¿Varía la confianza en el gobierno según partido?

Opinión sobre política × Ideología

- ¿La identificación izquierda/derecha predice posiciones en políticas sociales?

Ejemplo clásico: Medio informativo y grupo etario

Table: Medio informativo preferido según grupo etario (n=350)

	Internet	Prensa	Radio	TV	Sum
18-35	64	18	9	29	120
36-55	42	18	23	47	130
56+	17	11	10	62	100
Sum	123	47	42	138	350

¿Qué podemos ver a primera vista? El grupo 18–35 concentra más uso de Internet, mientras que el grupo 56+ tiende más hacia la televisión. Pero, ¿es esta diferencia **estadísticamente significativa**? Lo veremos más adelante.

Parte 3: Cómo Interpretar una Tabla Cruzada

Dos estrategias de lectura

Lectura por FILAS

Se calcula el porcentaje de cada celda respecto al **total de su fila**.

→ Responde: *"Del total de [categoría de fila], ¿qué proporción cae en cada columna?"*

Útil cuando la variable de fila es la independiente (ej. género como predictor).

Lectura por COLUMNAS

Se calcula el porcentaje de cada celda respecto al **total de su columna**.

→ Responde: *"Del total de [categoría de columna], ¿qué proporción proviene de cada fila?"*

Útil cuando la variable de columna es la independiente (ej. tipo de medio como predictor).

⚠️ **Regla práctica:** Los porcentajes van en la dirección de la variable **independiente** (la causa hipotética). Si el género "explica" el consumo de medios → porcentaje por filas (género en filas).

Lectura por FILAS — Paso a paso

Pregunta: ¿Varía el medio informativo preferido según el grupo etario?

Table: Porcentaje por fila (% dentro de cada grupo etario)

	Internet	Prensa	Radio	TV	Sum
18-35	53.3	15.0	7.5	24.2	100
36-55	32.3	13.8	17.7	36.2	100
56+	17.0	11.0	10.0	62.0	100

¿Cómo se lee?
Del grupo **18–35**: el ~58% prefiere Internet, ~21% TV, ~11% Radio y ~10% Prensa.
Del grupo **56+**: el ~50% prefiere TV, sólo ~15% Internet.
→ Se compara **horizontalmente** para ver si los perfiles difieren entre grupos etarios.

Lectura por COLUMNAS — Paso a paso

Pregunta: ¿De qué grupos etarios provienen los usuarios de cada medio?

Table: Porcentaje por columna (% dentro de cada medio informativo)

	Internet	Prensa	Radio	TV
18-35	52.0	38.3	21.4	21.0
36-55	34.1	38.3	54.8	34.1
56+	13.8	23.4	23.8	44.9
Sum	100.0	100.0	100.0	100.0

¿Cómo se lee?
De todos los usuarios de **Internet**: ~42% son jóvenes (18–35), ~39% adultos, sólo ~19% mayores.
De todos los usuarios de **TV**: los mayores de 56+ representan el porcentaje más alto.
→ Se compara **verticalmente** para ver la composición de cada medio.

Visualizando la tabla: gráfico de barras apiladas

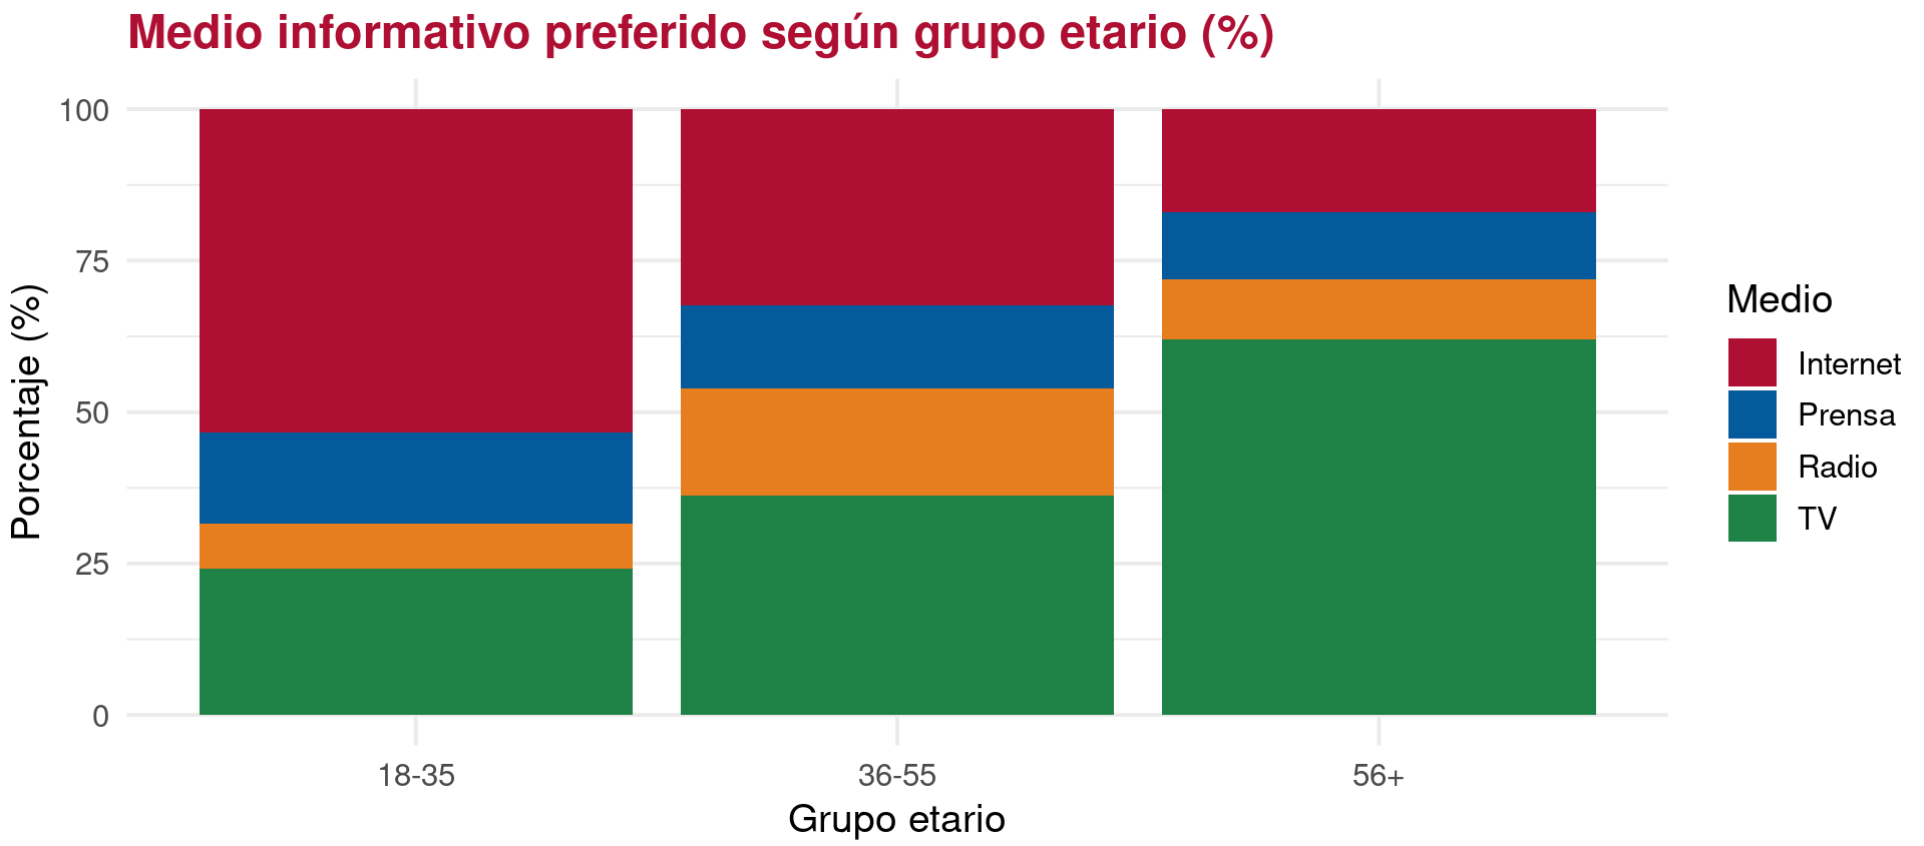

Parte 4: Test de Chi-cuadrado (χ^2)

¿Por qué necesitamos una prueba estadística?

El problema
Las diferencias que observamos en una tabla pueden deberse al **azar muestral**, no a una relación real entre las variables.

Con muestras pequeñas, diferencias grandes pueden ser producto del azar.
Con muestras grandes, diferencias pequeñas pueden ser "reales".

La solución: prueba de hipótesis
Formulamos dos hipótesis:

H_0 (nula): Las variables son **independientes** (no hay relación).
H_1 (alternativa): Las variables **están asociadas**.

Luego calculamos qué tan probable es observar los datos que tenemos **si H_0 fuera verdadera**.

El **test de Chi-cuadrado (χ^2)** es la prueba estándar para evaluar la independencia entre dos variables categóricas en una tabla de contingencia.

Lógica del Test Chi-cuadrado

1. **Calcular frecuencias esperadas:** Si las variables fueran independientes, ¿cuántas observaciones esperaríamos en cada celda?

$$E_{ij} = \frac{(\text{Total fila}_i) \times (\text{Total columna}_j)}{N}$$

2. **Calcular el estadístico χ^2:** Sumar las diferencias entre lo observado y lo esperado en todas las celdas.

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

3. **Obtener el valor p:** ¿Cuál es la probabilidad de obtener un χ^2 tan grande (o mayor) si H_0 fuera verdadera?

4. **Decidir:** Si $p < 0.05$ → rechazamos H_0 → hay evidencia de asociación entre las variables.

¿Qué es el Valor p?

El **valor p** (o p-value) es la probabilidad de observar un resultado **igual o más extremo** que el obtenido, **asumiendo que H_0 es verdadera**.

No es la probabilidad de que H_0 sea verdadera. Es la probabilidad de los **datos**, dado H_0.

$p \geq 0.05$
No rechazamos H_0. Los datos son **compatibles** con la hipótesis de independencia. No podemos concluir que haya asociación con el nivel de confianza habitual.

$p < 0.05$
Rechazamos H_0. La diferencia observada es **estadísticamente significativa**. Hay evidencia de asociación entre las variables (con un 95% de confianza).

⚠️ **Ojo con la interpretación:** Significancia estadística ≠ importancia sustantiva. Una relación puede ser estadísticamente significativa pero irrelevante en términos prácticos (especialmente con n muy grande).

Interpretando el resultado

```
## Estadístico χ²: 47.872

## Grados de libertad: 6

## Valor p: 0

##
## → p < 0.05: Se rechaza H₀.
## Conclusión: Existe una asociación estadísticamente significativa
## entre el grupo etario y el medio informativo preferido.
```

Cómo reportarlo en un informe:
"Se encontró una asociación estadísticamente significativa entre el grupo etario y el medio informativo preferido ($\chi^2(gl) = X.XX$, $p < 0.05$). Los jóvenes de 18-35 años reportan mayor consumo de Internet, mientras que el grupo de 56 años o más concentra un mayor uso de televisión."

Supuestos y limitaciones del Chi-cuadrado

Supuestos que deben cumplirse

- Las observaciones son **independientes** entre sí
- La frecuencia **esperada** en cada celda debe ser ≥ 5
- Las variables son **categóricas** (nominales u ordinales)
- Los datos provienen de una muestra **aleatoria**

Limitaciones

- No mide la **fuerza** ni la **dirección** de la asociación (sólo si existe)
- Sensible al **tamaño muestral**: con n grande casi todo resulta significativo
- No aplica si hay celdas con frecuencia esperada < 5 → usar test exacto de Fisher

Para medir la fuerza de la asociación se usan medidas complementarias:

- **V de Cramér**: entre 0 y 1 (0 = sin asociación, 1 = asociación perfecta)
- **Phi (ϕ)**: para tablas 2×2 específicamente

Resumen: Flujo de análisis con tablas cruzadas

1. **Construir la tabla** con `table()` en R. Agregar marginales con `addmargins()`.

2. **Calcular porcentajes** con `prop.table()`: por filas (`margin=1`) o columnas (`margin=2`), según cuál sea la variable independiente.

3. **Visualizar** con un gráfico de barras apiladas o agrupadas para comunicar el patrón.

4. **Probar la independencia** con `chisq.test()`. Reportar χ^2, grados de libertad y valor p.

¡Gracias!

fvillarroelr@udd.cl

Slide creado con **xaringan** y **XaringanThemer**